

Otimizando entregas na rede de supermercados Jaú

Arthur Martins Ferreira de Sousa - 14783601, Camila Aya Saito - 15635649, Guilherme Vaz de Oliveira Taratá - 10817476, Vinicius Moraes de Carvalho - 15642432

Abstract

Este documento introduz um problema híbrido de otimização desenvolvido para a rede de supermercados Jaú na cidade de São Carlos, Brasil. A abordagem integra otimização discreta de rotas e otimização não linear para modelagem de combustível e velocidade. O objetivo é encontrar um caminho que minimize os custos operacionais, dado o preço do combustível e do pagamento do motorista, sujeitos às distâncias e janelas de tempo de partida e funcionamento dos supermercados.

Index Terms

otimização não linear, otimização discreta, vehicle routing problem, método de newton, mínimos quadrados, Jaú Supermercados, travelling salesman problem

I. NOTAÇÃO E PARÂMETROS

O problema de rotas proposto é abordado como um problema misto de otimização discreta e contínua. Seja:

$$\min_{\pi, v, t_0} \mathbf{J}(\pi, v, t_0) \quad (1)$$

a função objetivo global de otimização, em que:

- $\pi \in \mathcal{S}_n$ é a permutação de rotas
- $v > 0$ é a velocidade média do veículo de transporte (km/h)
- $t_0 \in \mathbb{R}_+$ é o tempo de partida do veículo do depósito (em horas)

Seja N o número de nós (indexados de $i = 0, 1, \dots, N-1$), com o nó 0 o depósito do problema. Seja $D = [d_{ij}] \in \mathbb{R}^{N \times N}$ a matriz de distâncias (em km). Tempo é mensurado em horas, dinheiro em R\$.

A função objetivo, então, combinando combustível, custo do trabalhador e janelas de tempo, é expressa por:

$$J(\pi, v, t_0) = C_{\text{fuel}}(\pi, v) + C_{\text{driver}}(\pi, v) + P(t_0) \quad (2)$$

em que $P(t_0)$ é uma penalidade por partir do depósito rumo às entregas antes ou depois da janela de tempo determinada.

Parâmetros

- $p_f \in \mathbb{R}_+$: preço combustível (R\$/L)
- $w \in \mathbb{R}_+$: taxa motorista (R\$/h)
- $v_{\text{urbano}}, v_{\text{estrada}} > 0$ velocidade para meio urbano e estrada
- $f(v)$: função que modela eficiência (L/Km) do motor
- $(A, B) \in \mathbb{R}_+^2$: parâmetros do modelo do cálculo de eficiência do motor
- Janela de tempo: para nó i , o horário atendido precisa respeitar a abertura e o fechamento do estabelecimento $\in [o_i, c_i] \subset \mathbb{R}$

II. CARACTERIZAÇÃO MATEMÁTICA DO MODELO

Para resolver primeiro o problema discreto de rotas, isto é, a permutação ótima de rotas dado o espaço de permutações possíveis, é utilizado um solver combinatório da biblioteca [OR-Tools](#) - [Perron, Laurent and Furnon, Vincent \(2025\)](#). O objetivo desta etapa é encontrar a melhor ordem de visita das lojas, minimizando o custo operacional total de combustível e do motorista, sujeito (opcionalmente) a janelas de tempo rígidas.

Dado N o número total de nós (incluindo o depósito 0), e seja $C = [c_{ij}] \in \mathbb{R}^{N \times N}$ uma nova definição, a matriz de custos por arco, onde cada elemento é dado por:

$$c_{ij} = C_{\text{fuel}}(v_{ij}) + C_{\text{driver}}(v_{ij}).$$

O problema combinatório consiste em resolver o TSP (Travelling Salesman Problem) clássico - veja em [Toth and Vigo \(2002\)](#):

$$\pi^* = \arg \min_{\pi \in \mathcal{S}_N} \sum_{k=0}^{N-1} c_{\pi(k), \pi(k+1)} \quad , \quad \pi(N) = \pi(0) = 0 \quad (3)$$

O solver expressa o espaço de permutações S_n via dois componentes:

- 1) **RoutingIndexManager**, que estabelece o mapeamento entre índices internos do solver e os nós reais do problema.
- 2) **RoutingModel**, que representa todas as possíveis rotas Hamiltonianas, isto é, rotas que partem e retornam ao depósito visitando cada vértice (supermercado) somente uma vez.

Assim, o espaço de busca do solver coincide exatamente com o espaço de permutações S_N .

Em seguida, o `OR-Tools` solicita uma função de custo de transição entre os nós, função esta que será descrita continuamente:

$$\text{Cost}(i, j) = c_{ij}.$$

Esta função é então registrada no modelo, e dessa forma, o problema de minimização

$$\min_{\pi \in S_N} \sum_{k=0}^{N-1} c_{\pi(k), \pi(k+1)} \quad (4)$$

é resolvido exatamente utilizando a matriz de custos derivada do modelo contínuo, proposto em (5).

Para incorporar restrições temporais, o `OR-Tools` define uma dimensão de tempo (*Time Dimension*). Introduz-se, portanto, para cada nó i , uma variável de chegada T_i .

A relação de recorrência entre tempos é dada por:

$$T_j \geq T_i + t_{ij}, \quad t_{ij} = \frac{d_{ij}}{v_{ij}}.$$

Se cada nó i possui uma janela de atendimento $[o_i, c_i]$, então o solver impõe:

$$o_i \leq T_i \leq c_i.$$

O conjunto de permutações viáveis torna-se:

$$\mathcal{F} = \{\pi \in S_N : \text{todas as restrições de tempo são satisfeitas}\}.$$

Por fim, o método de busca combinatória do `OR-Tools`, minimizando o custo total sobre o conjunto viável $\mathcal{F}$ é realizado em duas fases:

- 1) **Construção da solução inicial** Utiliza-se uma heurística interna da biblioteca para construir rapidamente uma rota viável, denotada π_0 .
- 2) **Busca Local Guiada** O solver aplica movimentos combinatórios clássicos, tais como:
 - 2-opt,
 - 3-opt,
 - exchange,
 - relocate,
 - or-opt,

penalizando arcos sobreutilizados através de um mecanismo de penalidades adaptativas, permitindo escapar de mínimos locais.

Esse processo gera uma sequência de permutações:

$$\pi_0 \rightarrow \pi_1 \rightarrow \dots \rightarrow \pi^*,$$

tal que, para todo passo m ,

$$\sum_k c_{\pi^*(k), \pi^*(k+1)} \leq \sum_k c_{\pi_m(k), \pi_m(k+1)}.$$

A busca é encerrada após o tempo limite especificado pelo usuário.

Uma vez concluída a busca, o solver fornece a rota ótima percorrendo a cadeia de variáveis sucessoras:

$$\pi^*(0) = 0, \quad \pi^*(k+1) = \text{NextVar}(\pi^*(k)).$$

O conjunto de nós retornado corresponde exatamente ao minimizador do problema combinatório (3).

Fixada a permutação ótima π^* , o problema contínuo descrito adiante é resolvido para determinar os valores ótimos de velocidade e horário de partida:

$$(v^*, t_0^*) = \arg \min_{v, t_0} \mathbf{J}(\pi^*, v, t_0)$$

O resultado do framework híbrido será, então, a tripla:

$$(\pi^*, v^*, t_0^*),$$

que representa simultaneamente:

- a **rota combinatória ótima**
- a **velocidade ótima** segundo o modelo contínuo,
- o **horário de partida ótimo**.

Agora, para modelar o problema de consumo de combustível, podemos descrever o gasto segundo alguma relação $f(v)$ com a velocidade. Seja esta relação quadrática dada por (5):

$$f(v) = Av^2 + \frac{B}{v}, \quad \text{consumo total no percurso de } i \rightarrow j = F_{ij}^{(\text{eff})} = f(v_{ij})d_{ij} \quad (5)$$

Assim, o custo monetário de combustível por trecho fica:

$$C_{\text{fuel}}(v_{ij}) = p_f f(v_{ij})d_{ij}$$

Enquanto o custo para o motorista durante um trecho é expresso como:

$$C_{\text{driver}}(v_{ij}) = w \frac{d_{ij}}{v_{ij}}$$

Para estimar os parâmetros A, B da função $f(v)$, foi estudado o método dos mínimos quadrados não linear, que consiste em resolver o problema (6). Para isso, foram recolhidas observações empíricas $\{(v_i, f_i)\}_{i=1}^N$, em que cada f_i denota o consumo mensurado (L/Km) naquela velocidade média v_i (Km/h).

$$(\hat{A}, \hat{B}) = \arg \min_{A, B > 0} \sum_{i=1}^N [f_i - (Av_i^2 + B/v_i)]^2. \quad (6)$$

É possível resolver o problema pelo método dos mínimos quadrados, já que há uma forma fechada:

Algorithm 1: Estimativa de A e B pelo Método dos Mínimos Quadrados

Input: Observações $\{(v_i, f_i)\}_{i=1}^N$

Output: Estimativas $\hat{A}, \hat{B}$

// Construção da matriz de "regressão"

1 Formar a matriz $X \in \mathbb{R}^{N \times 2}$ com colunas $X_1 = (v_1^2, \dots, v_N^2)^\top$ e $X_2 = (1/v_1, \dots, 1/v_N)^\top$.

// Vetor de respostas

2 Formar $f = (f_1, f_2, \dots, f_N)^\top$.

// Cálculo das equações normais

3 Computar $M \leftarrow X^\top X$ e $b \leftarrow X^\top f$.

// Resolver o sistema linear

4 Calcular $\beta = (A, B)^\top \leftarrow M^{-1}b$.

5 **Retornar:** $\hat{A} = \beta_1, \hat{B} = \beta_2$.

Outra maneira de abordar este problema, é pelo método de Newton, que segundo [Nocedal and Wright \(2006\)](#), calculamos o gradiente e a matriz Hessiana:

$$\nabla f = \begin{bmatrix} 2 \sum_{i=1}^N (Av_i^4 + Bv_i - f_i v_i^2) \\ 2 \sum_{i=1}^N (Av_i + \frac{B}{v_i^2} - \frac{f_i}{v_i}) \end{bmatrix}$$

$$H = 2 \begin{bmatrix} \sum_{i=1}^N v_i^4 & \sum_{i=1}^N v_i \\ \sum_{i=1}^N v_i & \sum_{i=1}^N \frac{1}{v_i^2} \end{bmatrix}$$

Algorithm 2: Método de Newton para estimação de A e B **Data:** Velocidades $\{v_i\}_{i=1}^N$, consumos $\{f_i\}_{i=1}^N$ **Result:** Estimativas $\hat{A}, \hat{B}$ **1 Inicializar:** $\theta^{(0)} = (A^{(0)}, B^{(0)})^\top$ **2 for** $k = 0, 1, 2, \dots$ **até convergência do****3** Calcular o gradiente:

$$\nabla f(\theta^{(k)})$$

4 Calcular a Hessiana:

$$H(\theta^{(k)})$$

5 Atualizar parâmetros via passo de Newton:

$$\theta^{(k+1)} = \theta^{(k)} - H(\theta^{(k)})^{-1} \nabla f(\theta^{(k)})$$

6 **if** $\|\theta^{(k+1)} - \theta^{(k)}\| < \varepsilon$ **then****7** | **parar****8 return** $(\hat{A}, \hat{B}) = \theta^{(k+1)}$

Agora, introduzindo a componente $P(t_0)$ do tempo de partida (normalmente quadrática) com sua penalidade, que pode ser tanto expressa de maneira simples (7), quanto de maneira alternativa considerando janelas de abertura e fechamento dos supermercados, apresentada em (11) logo mais.

$$P(t_0) = \lambda(t_0 - t_{\text{pref}})^2 \quad (7)$$

Em que o parâmetro λ controla a força da penalidade e t_{pref} é o tempo preferível de partida, afetando globalmente t_0 , sem diferenciar nós individuais.

Estimados os coeficientes A e B , substituindo os custos do combustível C_{fuel} e do motorista C_{driver} em (2) junto a penalidade do tempo em (7), o custo total tem uma função contínua:

$$\mathbf{J}(v, t_0) = d_{ij} \left[A p_f v_{ij}^2 + \frac{B p_f + w}{v_{ij}} \right] + \lambda(t_0 - t_{\text{pref}})^2 \in \mathbb{R}^2 \quad (8)$$

A função (8) forma uma superfície convexa. Ao longo do eixo da velocidade, $\mathbf{J}$ tem formato de U , enquanto ao longo do eixo t_0 , $\mathbf{J}$ tem forma de parábola centrada em t_{pref} .




Fig. 1: Função de Custo para métricas especificadas do problema

Por simplicidade da função, é possível encontrar a velocidade ótima v^* que minimiza o custo de combustível naquele trecho, simplesmente derivando a função de custo em relação à variável velocidade:

$$\nabla_v \mathbf{J} = \frac{\partial \mathbf{J}}{\partial v} = d_{ij} \left[2Ap_f v_{ij} - \frac{Bp_f + w}{v_{ij}^2} \right]$$

Assim:

$$\begin{aligned} \nabla_v \mathbf{J} = 0 &\Rightarrow \\ 2Ap_f v_{ij} &= \frac{Bp_f + w}{v_{ij}^2} \Leftrightarrow \end{aligned}$$

$$v_{ij} = v_{ij}^* = \left(\frac{Bp_f + w}{2Ap_f} \right)^{1/3}$$

Além da formulação simples já apresentada em (7), consideremos uma formulação mais rica com penalidades early/late. A formulação utilizada nas implementações considera penalidades por nó, distinguindo atrasos e chegadas antecipadas e permitindo janelas (por nó) do tipo $[o_i, c_i]$.

Seja uma rota fixa π com M segmentos (ou seja, $M + 1$ nós incluindo o depósito na posição inicial). Denotamos por d_k a distância do k -ésimo segmento da rota e por v_k a velocidade aplicada nesse segmento. Definimos os deslocamentos cumulativos

$$\Delta_0 = 0, \quad \Delta_k = \sum_{m=0}^{k-1} \frac{d_m}{v_m}, \quad k = 1, \dots, M. \quad (9)$$

Se o veículo parte de um horário τ (nas implementações τ é o parâmetro otimizado, equivalente a t_0), então o horário de chegada ao nó k é

$$T_k(\tau) = \tau + \Delta_k. \quad (10)$$

Para cada nó k com janela $[o_k, c_k]$ definimos a penalidade quadrática *assimétrica*:

$$p_k(\tau) = \lambda_{\text{early}} (o_k - T_k(\tau))_+^2 + \lambda_{\text{late}} (T_k(\tau) - c_k)_+^2, \quad (11)$$

onde $(x)_+ = \max(x, 0)$. As constantes $\lambda_{\text{early}} \geq 0$ e $\lambda_{\text{late}} \geq 0$ controlam, respectivamente, a severidade da penalidade por chegar cedo e por chegar tarde.

A penalidade total por janelas é então a soma sobre os nós:

$$P_{\text{windows}}(\tau) = \sum_{k=0}^M p_k(\tau). \quad (12)$$

Por fim, a função objetivo de partida com penalidades em (2a) significa o custo que o algoritmo de otimização unidimensional (minimização sobre τ) busca minimizar, combinando o custo do motorista (proporcional ao tempo total de viagem) e as penalidades de janela:

$$J(\tau) = d_{ij} \left[Ap_f v_{ij}^2 + \frac{Bp_f + w}{v_{ij}} \right] + P_{\text{windows}}(\tau), \quad (13)$$

onde

$$T_{\text{total}} = \Delta_M = \sum_{m=0}^{M-1} \frac{d_m}{v_m}$$

é o tempo total (note que T_{total} independe de τ e, por isso, na prática apenas desloca o custo base; as penalidades determinam o τ^* ótimo quando as janelas são relevantes).




Fig. 2: Função de Custo para métricas especificadas do problema

No fim, a solução buscada é

$$\tau^* = \arg \min_{\tau_{\min} \leq \tau \leq \tau_{\max}} J(\tau),$$

Além disso, a penalidade global simples (7) é um caso particular da formulação por nós quando:

- existe apenas um nó de interesse (por exemplo, a rota inteira é representada por um único horário de referência), ou
- escolhemos parâmetros $\lambda_{\text{early}} = \lambda_{\text{late}} = \lambda$ e definimos janelas simétricas em torno de t_{pref} de modo que a soma das penalidades por nó se reduza a uma penalidade quadrática única centrada em t_{pref} .

Em termos práticos, a expressão $\lambda(t_0 - t_{\text{pref}})^2$ corresponde a $P_{\text{windows}}(\tau)$ com uma única janela global centrada em t_{pref} .

Observe que quando todas as janelas $[o_k, c_k]$ são largas (por exemplo, 8h–18h) e a rota inteira (depósito $\rightarrow$ supermercados $\rightarrow$ depósito) cabe dentro dessas janelas para a maioria dos τ em $[\tau_{\min}, \tau_{\max}]$, as penalidades serão nulas para muitos τ e o termos que dominam $J(\tau)$ serão os custos. Nesse cenário vários τ podem produzir praticamente o mesmo J e o otimizador retorna um valor arbitrário dentro do intervalo ótimo (ex.: 11.78), que deve ser interpretado como horas decimais (11.78 h = 11 h 46.8 min).

III. APLICAÇÕES DO MODELO

Para a estruturação matemática do projeto funcionar e ser modular dentro do possível, foi construída uma plataforma que visa auxiliar o usuário a estruturar sua própria análise com base no seu depósito de interesse.

Para isso, a primeira etapa prática do projeto constou em coletar as latitudes e longitudes das 8 unidade do Jaú na cidade de São Carlos e do depósito num arquivo .csv. Nesse arquivo, a primeira linha deve sempre constar as coordenadas do depósito.

Em seguida, uma matriz de distâncias reais foi construída utilizando uma API externa, em que a distância entre cada elemento era registrada de acordo com cálculos obtidos a partir das latitudes e longitudes, como visto em (3a e 3b).





Fig. 3: Depósito Ilustrativo

Em seguida, um módulo criado para performar os otimizadores foi programado e integrado com os dados do problema.

Por fim, visando democratizar o entendimento e o conhecimento de otimização a jovens estudantes, foi criado um Dashboard interativo, onde o usuário consegue personalizar o problema de acordo com preferências e visualizar as melhores soluções para sua abordagem (4). Esta ferramenta interativa permite configurar penalidades da função objetivo e explicitar informações relevantes. Também é possível modificar as janelas de tempo de abertura e fechamento dos supermercados, assim como os horários mínimos e máximos de partida e localização do depósito no código-fonte do projeto, disponível no [repositório online](#).



Fig. 4: Dashboard completo

Também, foi feito um vídeo no formato de animação explicando e contextualizando o problema de maneira didática e acessível à comunidade externa do ambiente científico.

IV. CONSIDERAÇÕES FINAIS

Após a implementação dos métodos, pode-se notar que o problema proposto inicialmente foi otimizado. Lembre-se que o problema geral de otimização vive num espaço de domínios mistos,

$$(\pi, v, t_0) \in \mathcal{S}_n \times \mathbb{R}_+^2$$

- A parte discreta (π) define uma busca combinatória, resolvida com o auxílio da ferramenta OR-Tools
- a parte contínua (v, t_0) define um subespaço convexo, suave e de baixa dimensão, resolvido analiticamente ou com procedimentos numéricos.

Assim, finalmente, para resolver o problema, basta encontrar a rota ótima (π^*) que minimiza os custos operacionais e fixada esta rota, minimizar $\mathbf{J}(v, t_0)$ para refinar a eficiência da operação.

Este framework misto de otimização permite que o usuário ou analista tenha ambas interpretações econômicas e computacionais tratáveis a respeito do problema de transportes. O ótimo analítico v^* quantifica o balanço entre combustível e custos do tempo, enquanto uma superfície convexa $J(v, t_0)$ providencia uma geometria interpretável para refinamento operacional. Quando a melhor rota é escolhida, a otimização contínua define a melhor política de direção visando economia dos custos e tempo.

Este projeto consta como uma abordagem inicial ao estudo de técnicas de otimização não linear e discreta, e serve como base de aprendizado aos alunos. No futuro, melhorias podem ser estudadas, como definir funções mais complexas para o gasto de combustível, considerar tempo de parada entre depósitos, ou senão modelar rotas que partem de um depósito, visitam os supermercados e chegam até outro depósito.

REFERENCES

- Nocedal, J. and Wright, S. (2006). *Numerical Optimization*. Springer Series in Operations Research and Financial Engineering. Springer New York.
- Perron, Laurent and Furnon, Vincent (2025). Or-tools: Google's operations research tools. <https://developers.google.com/optimization>.
- Toth, P. and Vigo, D. (2002). *1. An Overview of Vehicle Routing Problems*, pages 1–26. SIAM.