

Tarefa Lab. 2 - Regressão Linear Múltipla

Estagiário: Riquelme N. Santos (riquelme@usp.br)
Supervisora: Prof.a Dra. Reiko Aoki (reiko@icmc.usp.br)

Grupo 6:

- Camila Aya Saito - 15635649
- Guilherme Vaz de Oliveira Taratá - 10817476
- Julio Cesar Alves Araujo Fuganti - 15638792
- Lina Sun Young Park - 11402617
- Luis Felipe Vogel Lopes - 13730051
- Pedro Henrique Gonzalez Moracci - 8556418
- Romulo Ferreira da Silva - 13734326
- Vinicius de Moraes - 13749910
- Vinicius Moraes de Carvalho - 15642432

Observações Importantes:

1. **Entrega:** A atividade deve ser entregue em formato PDF ou HTML, gerado a partir deste arquivo R Markdown.
2. **Código:** Todo código R deve estar visível e executável. Comentários no código são bem-vindos.
3. **Interpretações:** As interpretações devem ser feitas no contexto do problema, considerando as unidades das variáveis.
4. **Gráficos:** Todos os gráficos devem ter títulos e rótulos apropriados nos eixos.
5. **Critérios de Avaliação:**
 - Correção técnica do código R
 - Adequação das interpretações
 - Qualidade dos gráficos
 - Clareza na apresentação dos resultados
 - Análise crítica dos resultados obtidos

Boa sorte!

Descrição do Dataset

O dataset `BGSgirls.csv` contém dados do Berkeley Guidance Study de meninas nascidas em 1928-29 em Berkeley, CA. As variáveis disponíveis são:

Variáveis aos 2 anos:

- **WT2:** Peso aos 2 anos (kg)
- **HT2:** Altura aos 2 anos (cm)

Variáveis aos 9 anos:

- **WT9:** Peso aos 9 anos (kg)
- **HT9:** Altura aos 9 anos (cm)
- **LG9:** Circunferência da perna aos 9 anos (cm)
- **ST9:** Força aos 9 anos (kg)

Variáveis aos 18 anos:

- **WT18:** Peso aos 18 anos (kg)
- **HT18:** Altura aos 18 anos (cm) (**VARIÁVEL RESPOSTA PRINCIPAL**)
- **LG18:** Circunferência da perna aos 18 anos (cm)
- **ST18:** Força aos 18 anos (kg)
- **BMI18:** Índice de Massa Corporal aos 18 anos, calculado como $WT18/(HT18/100)^2$

Outras variáveis:

- **Soma:** Somatotipo, escala de 1 a 7 do tipo corporal

Exercícios

1. Carregamento e Exploração dos Dados

a) Carregue o dataset `BGSgirls.csv` e examine sua estrutura usando `str()` e `head()`.

```
# Seu código aqui
#setwd("C:/home/drysaliva/Desktop/2025_2/REG_LAB_2")
data <- read.table("./BGSgirls.csv", header = TRUE, sep = ";", dec = ",")
str(head(data))
```

```
## 'data.frame':   6 obs. of  13 variables:
## $ X      : int  67 68 69 70 71 72
## $ WT2    : num  13.6 11.3 17 13.2 13.3 11.3
## $ HT2    : num  87.7 90 89.6 90.3 89.4 85.5
## $ WT9    : num  32.5 27.8 44.4 40.5 29.9 22.8
## $ HT9    : num  133 135 142 137 136 ...
## $ LG9    : num  28.4 26.9 31.9 31.8 27.7 23.4
## $ ST9    : int   74 65 104 79 83 60
## $ WT18   : num  56.9 49.9 55.3 65.9 62.3 47.4
## $ HT18   : num  159 166 162 168 171 ...
## $ LG18   : num  34.6 33.8 35.1 39.3 36.3 31.8
## $ ST18   : int  143 117 143 148 152 126
## $ BMI18  : num  22.5 18.1 21 23.4 21.3 17.4
## $ Soma   : num   5 4 5.5 5.5 4.5 3
```

b) Calcule as medidas descritivas (média, mediana, desvio padrão, mínimo, máximo) para as variáveis HT18 e WT9.

```
ht <-data$HT18
n <- dim(data)[1]
media_ht <- sum(ht)/n
v_ht <- (sum(ht^2) - n*(mean(ht))^2)/(n-1)
dp_ht <- sqrt(v_ht)


wt <-data$WT9
media_wt <- sum(wt)/n
v_wt <- (sum(wt^2) - n*(mean(wt))^2)/(n-1)
dp_wt <- sqrt(v_wt)
cat("\n=== ESTATÍSTICAS DE HT18 ===\n")
cat("Media de HT18:", media_ht, "\n")
cat("Mediana de HT18:", median(ht), "\n" )
cat("Desvio Padrao de HT18:", dp_ht, "\n")
cat("Mínimo:", min(ht), "\n")
cat("Máximo:", max(ht), "\n")

cat("\n=== ESTATÍSTICAS DE WT9 ===\n")
cat("Media de WT9:", media_wt, "\n")
cat("Mediana de WT9:", median(wt), "\n" )
cat("Desvio Padrao de WT9:", dp_wt, "\n" )
cat("Mínimo:", min(wt), "\n")
cat("Máximo:", max(wt), "\n")
```


```
##
## === ESTATÍSTICAS DE HT18 ===
## Media de HT18: 166.5443
## Mediana de HT18: 166.75
## Desvio Padrao de HT18: 6.074886
## Mínimo: 153.6
## Máximo: 183.2
##
## === ESTATÍSTICAS DE WT9 ===
## Media de WT9: 31.62143
## Mediana de WT9: 30.65
## Desvio Padrao de WT9: 5.82416
## Mínimo: 22
## Máximo: 47.4
```

c) Construa um gráfico de dispersão entre HT18 (eixo y) e WT9 (eixo x) e histogramas para as variáveis HT18 e WT9 com títulos e rótulos apropriados.


```
plot(wt, ht,  
     main = "Altura aos 18 anos em relacao ao peso aos 9 anos",  
     xlab = "WT9(kg)",  
     ylab = "HT18(cm)",  
     pch = 16,  
     col = "green")
```



```
hist(data$HT18,  
      xlab = "Alturas",  
      ylab = "Frequência",  
      col="darkblue",  
      border="black",  
      main="Histograma da Altura aos 18 anos");
```



```
hist(data$WT9,  
      xlab = "Pesos",  
      ylab = "Frequência",  
      col="darkgreen",  
      border="black",  
      main = "Histograma de Peso aos 9 anos");
```



d) Interprete os resultados. Quais suas percepções sobre os dados?

Aparenta existir uma pequena correlação positiva entre as duas variáveis.

2. Cálculos Manuais das Estimativas

Para o modelo $E(HT18|X) = \beta_0 + \beta_1 HT2 + \beta_2 WT2 + \beta_3 HT9 + \beta_4 WT9 + \beta_5 ST9$:

a) Monte a matriz de design X incluindo a coluna de 1s para o intercepto e mostre as primeiras 10 linhas.

```
X <- matrix(c(rep(1, n), data$HT2, data$WT2, data$HT9, data$WT9, data$ST9),
            ncol = 6, nrow = n, byrow = FALSE)
Y <- matrix(data$HT18, ncol = 1, nrow = n)
X[1:10,1:6]
```

```
##      [,1] [,2] [,3] [,4] [,5] [,6]
## [1,]    1 87.7 13.6 133.4 32.5   74
## [2,]    1 90.0 11.3 134.8 27.8   65
## [3,]    1 89.6 17.0 141.5 44.4  104
## [4,]    1 90.3 13.2 137.1 40.5   79
## [5,]    1 89.4 13.3 136.1 29.9   83
## [6,]    1 85.5 11.3 130.6 22.8   60
## [7,]    1 90.2 11.6 136.0 30.0   67
## [8,]    1 82.2 11.6 128.0 24.3   44
## [9,]    1 85.6 12.4 132.4 29.9   76
## [10,]   1 97.3 17.0 152.5 44.5   81
```

b) Calcule os coeficientes usando a fórmula matricial.

```
XtX <- t(X) %*% X
XtX_inv <- solve(XtX)
XtX_inv_Xt <- XtX_inv %*% t(X)
betas <- XtX_inv_Xt %*% Y
betas
p <- dim(betas)[1]
k <- p - 1
```

```
##      [,1]
## [1,]  9.16351566
## [2,]  0.12717161
## [3,]  0.32536090
## [4,]  1.17452040
## [5,] -0.39538587
## [6,] -0.06754503
```

c) Compare seus resultados com a função `lm()` do R e interprete cada coeficiente no contexto do problema.

```
lm(HT18~ HT2+ WT2+ HT9+ WT9+ST9,data=data)
cat("A função lm() obteve os mesmos coeficientes, divergindo em alguns casos no quinto dígito. Os coeficientes positivos como HT2, WT2, HT9 indicam uma correlação positiva com a variável alvo, enquanto que os negativos WT9 e ST9 indicam uma correlação negativa, apesar de ST9 apresentar uma correlação pouco relevante. Isso condiz com as expectativas gerais para a previsão da altura aos dezoito anos: altura aos nove anos e a variável mais importante logo em seguida temos peso aos nove anos seguido por peso aos dois anos com menor influência, altura aos dois anos com uma influência ainda menor e por fim temos força aos nove anos com uma influência bem pequena, podendo indicar que esta variável não possui relação linear com a variável resposta. ")
```

```
##
## Call:
## lm(formula = HT18 ~ HT2 + WT2 + HT9 + WT9 + ST9, data = data)
##
## Coefficients:
## (Intercept)          HT2          WT2          HT9          WT9          ST9
##    9.16352      0.12717      0.32536      1.17452     -0.39539     -0.06755
##
## A função lm() obteve os mesmo coeficientes, divergindo em alguns casos no quinto dígito
## Os coeficientes positivos como HT2,WT2,HT9 indicam uma correlação positiva com a variável
## alvo, enquanto que os negativos WT9 e ST9 uma correlação negativa, apesar de ST9 apresentar
## uma correlação pouco relevante. Isso condiz com as expectativas gerais para a previsão da
## altura aos dezoito anos: altura aos nove anos e a variável mais importante logo em seguida
## temos peso aos nove anos seguido por peso aos dois anos com menor influência altura aos
## dois anos com uma influência ainda menor e por fim temos força aos nove anos com uma
## influência bem pequena, podendo indicar que esta variável não possui relação linear com
## a variável resposta.
```


3. Análise de Resíduos e Somas de Quadrados

a) Calcule os valores preditos e os resíduos do modelo.

```
# Valores preditos usando notação matricial
#  $\hat{Y} = X \hat{\beta}$ 
Y_est <- X %*% betas

# Resíduos
#  $e = Y - \hat{Y}$ 
residuos <- Y - Y_est

cat("Primeiros 10 valores:\n")
comparacao <- data.frame(
  Observado = Y[1:10, 1],
  Predito = Y_est[1:10, 1],
  Residuo = residuos[1:10, 1]
)
print(round(comparacao, 2))

# Verificação: soma dos resíduos deve ser aprox. 0
cat("\nSoma dos resíduos:", sum(residuos), "\n")
```

```
## Primeiros 10 valores:
##      Observado Predito Residuo
## 1      158.9   163.57   -4.67
## 2      166.0   167.23   -1.23
## 3      162.2   167.70   -5.50
## 4      167.8   164.62    3.18
## 5      170.9   167.28    3.62
## 6      164.9   164.04    0.86
## 7      168.1   167.76    0.34
## 8      164.0   161.15    2.85
## 9      163.3   162.63    0.67
## 10     183.2   183.12    0.08
##
## Soma dos resíduos: -1.769877e-09
```

b) Calcule as somas de quadrados: SQ_{Total} , $SQ_{Regresso}$ e $SQ_{Resduos}$ manualmente (sem funções prontas do R).

```
# Vetor unitário para facilitar cálculos
u <- matrix(rep(1, n), ncol = 1)

# SQ Total
SQ_total <- t(Y) %*% Y - ((t(u) %*% Y)^2)/n
SQ_total <- as.numeric(SQ_total)

# SQ Regressão
SQ_regressao <- t(betas) %*% t(X) %*% Y - ((t(u) %*% Y)^2)/n
SQ_regressao <- as.numeric(SQ_regressao)

# SQ Resíduos
```

```

SQ_residuos <- t(residuos) %*% residuos
SQ_residuos <- as.numeric(SQ_residuos)

# Verificação da decomposição
cat("=== DECOMPOSIÇÃO DA VARIABILIDADE ===\n")
cat("SQ Total:", round(SQ_total, 2), "\n")
cat("SQ Regressão:", round(SQ_regressao, 2), "\n")
cat("SQ Resíduos:", round(SQ_residuos, 2), "\n")

```

```

## === DECOMPOSIÇÃO DA VARIABILIDADE ===
## SQ Total: 2546.39
## SQ Regressão: 1868.08
## SQ Resíduos: 678.31

```

c) Verifique que $SQ_{Total} = SQ_{Regresso} + SQ_{Resduos}$.

```

cat("Verificação (SQ_reg + SQ_res):", round(SQ_regressao + SQ_residuos, 2), "\n")
cat("e SQ_total:", round(SQ_total, 2), "\n")
cat("A diferença é pouco significativa de", round(SQ_total - (SQ_regressao + SQ_residuos), 8))

```

```

## Verificação (SQ_reg + SQ_res): 2546.39
## e SQ_total: 2546.39
## A diferença é pouco significativa de -2.9e-07

```

4. Coeficiente de Determinação

a) Calcule o R^2 usando a fórmula $R^2 = \frac{SQ_{Regresso}}{SQ_{Total}}$.

```
R2 <- SQ_regressao / SQ_total  
cat("R^2:", round(R2, 4))
```

```
## R^2: 0.7336
```

b) Calcule o R^2 ajustado usando $R^2_{adj} = 1 - \frac{(1-R^2)(n-1)}{n-p}$.

```
R2_ajustado <- 1 - ((1-R2)*(n-1)/(n-p))  
cat("R^2 ajustado:", round(R2_ajustado, 4))
```

```
## R^2 ajustado: 0.7128
```

c) Interprete os resultados. Qual é a qualidade do ajuste do modelo?

```
cat("No caso analisado, o R^2 obtido foi 0,7336, indicando que aproximadamente 73,36%  
da variação de Y é explicada pelo modelo. Já o R^2 ajustado foi 0,7128, o que representa  
uma redução esperada quando se considera o número de variáveis incluídas. Essa diferença  
indica que, embora o modelo apresente um bom poder explicativo, nem todas as variáveis podem  
estar contribuindo de forma significativa, e algumas podem ter efeito limitado sobre a  
resposta. Ainda assim, o valor de R^2 ajustado mostra que o modelo mantém uma boa capacidade  
de explicação mesmo após a correção. A significância de cada variável pode ser verificada  
detalhadamente a seguir pelos testes de hipóteses e a tabela ANOVA a seguir.")
```

```
## No caso analisado, o R^2 obtido foi 0,7336, indicando que aproximadamente 73,36%  
## da variação de Y é explicada pelo modelo. Já o R^2 ajustado foi 0,7128, o que representa  
## uma redução esperada quando se considera o número de variáveis incluídas. Essa diferença  
## indica que, embora o modelo apresente um bom poder explicativo, nem todas as variáveis podem  
## estar contribuindo de forma significativa, e algumas podem ter efeito limitado sobre a  
## resposta. Ainda assim, o valor de R^2 ajustado mostra que o modelo mantém uma boa capacidade  
## de explicação mesmo após a correção. A significância de cada variável pode ser verificada  
## detalhadamente a seguir pelos testes de hipóteses e a tabela ANOVA a seguir.
```

5. Testes de Hipóteses

a) Calcule o Quadrado Médio dos Resíduos (QM_{Res}) e a matriz de covariâncias $(X^T X)^{-1}$.

```
QM_residuos <- (SQ_residuos)/(n-p)
Matriz_cov <- QM_residuos*XtX_inv

cat("QM_Res calculado:", round(QM_residuos, 3), "\n")
print(round(Matriz_cov, 4))

## QM_Res calculado: 10.599
##      [,1]      [,2]      [,3]      [,4]      [,5]      [,6]
## [1,] 178.4869 -0.7900  0.4211 -1.0493  0.5959  0.1346
## [2,] -0.7900  0.0396 -0.0388 -0.0181  0.0059  0.0016
## [3,]  0.4211 -0.0388  0.1798  0.0122 -0.0249 -0.0033
## [4,] -1.0493 -0.0181  0.0122  0.0215 -0.0091 -0.0023
## [5,]  0.5959  0.0059 -0.0249 -0.0091  0.0131  0.0004
## [6,]  0.1346  0.0016 -0.0033 -0.0023  0.0004  0.0011
```

b) Para cada coeficiente β_j , teste manualmente (sem funções prontas do R) $H_0 : \beta_j = 0$ vs $H_1 : \beta_j \neq 0$ com $\alpha = 0.05$ usando a estatística t .

```
se_beta <- sqrt(diag(QM_residuos * XtX_inv))

# Estatística t
t_values <- betas / se_beta

# Valor crítico para alfa = 0.05
t_crit <- qt(0.975, df = n - p)

# Resultado do teste
reject_H0 <- abs(t_values) > t_crit

resultados <- data.frame(
  Coeficiente = c("Intercepto", "HT2", "WT2", "HT9", "WT9", "ST9"),
  Beta = round(betas, 4),
  Erro_Padiao = round(se_beta, 4),
  t = round(t_values, 4),
  Significativo = abs(t_values) > t_crit
)

print(resultados)
cat("\nValor crítico t (=0.05):", round(t_crit, 4))

##      Coeficiente      Beta Erro_Padiao      t Significativo
## 1 Intercepto    9.1635    13.3599  0.6859         FALSE
## 2          HT2    0.1272     0.1990  0.6390         FALSE
## 3          WT2    0.3254     0.4241  0.7672         FALSE
## 4          HT9    1.1745     0.1466  8.0128          TRUE
## 5          WT9   -0.3954     0.1144 -3.4553          TRUE
## 6          ST9   -0.0675     0.0338 -1.9981          TRUE
##
## Valor crítico t (=0.05): 1.9977
```

c) Calcule os intervalos de confiança de 95% para todos os coeficientes manualmente (sem funções prontas do R).

```
IC <- data.frame(
  Coeficiente = c("Intercepto", "HT2", "WT2", "HT9", "WT9", "ST9"),
  Beta = round(betas, 4),
  IC_Inferior = round(betas - t_crit * se_beta, 4),
  IC_Superior = round(betas + t_crit * se_beta, 4)
)

print(IC)
```

##	Coeficiente	Beta	IC_Inferior	IC_Superior
## 1	Intercepto	9.1635	-17.5260	35.8530
## 2	HT2	0.1272	-0.2704	0.5248
## 3	WT2	0.3254	-0.5218	1.1726
## 4	HT9	1.1745	0.8817	1.4673
## 5	WT9	-0.3954	-0.6240	-0.1668
## 6	ST9	-0.0675	-0.1351	0.0000

d) Interprete os resultados. Com esse teste, quais variáveis são significativas?

```
sig_vars <- resultados$Coeficiente[resultados$Significativo]
nao_sig_vars <- resultados$Coeficiente[!resultados$Significativo]

cat("VARIÁVEIS SIGNIFICATIVAS (p < 0.05):\n")
cat(paste("•", sig_vars, collapse="\n"), "\n\n")

cat("VARIÁVEIS NÃO SIGNIFICATIVAS (p > 0.05):\n")
cat(paste("•", nao_sig_vars, collapse="\n"), "\n\n")

cat("CONCLUSÕES:\n")
cat("• HT9 é o preditor mais forte do modelo.\n")
cat("• WT9 apresenta um efeito negativo estatisticamente significativo.\n")
cat("• ST9 também é estatisticamente significativa, mas com efeito pequeno.\n")
cat("• As demais variáveis não possuem efeito estatisticamente significativo.\n")
cat("• O modelo apresenta bom poder explicativo (R² = 73.36%).\n")
```

```
## VARIÁVEIS SIGNIFICATIVAS (p < 0.05):
## • HT9
## • WT9
## • ST9
##
## VARIÁVEIS NÃO SIGNIFICATIVAS (p > 0.05):
## • Intercepto
## • HT2
## • WT2
##
## CONCLUSÕES:
## • HT9 é o preditor mais forte do modelo.
## • WT9 apresenta um efeito negativo estatisticamente significativo.
## • ST9 também é estatisticamente significativa, mas com efeito pequeno.
## • As demais variáveis não possuem efeito estatisticamente significativo.
## • O modelo apresenta bom poder explicativo (R² = 73.36%).
```

6. Intervalos de Confiança e Predição

a) Para uma menina com as seguintes medidas: HT2 = 90, WT2 = 12, HT9 = 135, WT9 = 30, ST9 = 20:

- Calcule o valor predito para a altura aos 18 anos;
- Calcule o intervalo de confiança de 95% para a altura média esperada;
- Calcule o intervalo de predição de 95% para a altura individual.

```
HT2 <- 90
WT2 <- 12
HT9 <- 135
WT9 <- 30
ST9 <- 20

X0 <- matrix(c(1, HT2, WT2, HT9, WT9, ST9),
             ncol = 6, nrow = 1)

t_critico_inf <- qt(0.05/2, n - p)
t_critico_sup <- qt(1 - 0.05/2, n - p)

# Valor predito para altura aos 18 anos
Y0_esperanca <- X0 %*% betas # Y0 = Y0_esperanca
Y0_esperanca <- as.numeric(Y0_esperanca)
cat("Valor predito (altura aos 18 anos) = ", Y0_esperanca, "cm\n")

# Variância do valor predito
var_Y0_esperanca <- QM_residuos * X0 %*% XtX_inv %*% t(X0)
var_Y0_esperanca <- as.numeric(var_Y0_esperanca)

# IC para esperanca
IC_esp_inf <- Y0_esperanca - t_critico_sup * sqrt(var_Y0_esperanca)
IC_esp_sup <- Y0_esperanca + t_critico_inf * sqrt(var_Y0_esperanca)
cat("IC (95%): [", round(IC_esp_inf, 4), ",", round(IC_esp_sup, 4), "]\n")

# Variância para predição
var_Y0_predicao <- QM_residuos * (1 + X0 %*% XtX_inv %*% t(X0))
var_Y0_predicao <- as.numeric(var_Y0_predicao)

# IP para nova observação
IP_inf <- Y0_esperanca - t_critico_sup * sqrt(var_Y0_predicao)
IP_sup <- Y0_esperanca + t_critico_inf * sqrt(var_Y0_predicao)
cat("IP (95%): [", round(IP_inf, 4), ",", round(IP_sup, 4), "]\n")

## Valor predito (altura aos 18 anos) = 169.8611 cm
## IC (95%): [ 167.0396 , 172.6825 ]
## IP (95%): [ 162.7717 , 176.9504 ]
```

b) Compare com funções prontas do R (`predict()` com `interval = "confidence"` e `interval = "prediction"`).

```
dados <- data.frame(HT2 = data$HT2, WT2 = data$WT2, HT9 = data$HT9,
                    WT9 = data$WT9, ST9 = data$ST9, HT18 = data$HT18)
modelo_r <- lm(HT18 ~ HT2 + WT2 + HT9 + WT9 + ST9, data = dados)

cat("Intervalo de confiança com função do R: \n")
predict(modelo_r, data.frame(X0), interval = "confidence", level = 0.95)

cat("\nIntervalo de predição com função do R: \n")
predict(modelo_r, data.frame(X0), interval = "prediction", level = 0.95)
```

```
## Intervalo de confiança com função do R:
##      fit      lwr      upr
## 1 169.8611 167.0396 172.6825
##
## Intervalo de predição com função do R:
##      fit      lwr      upr
## 1 169.8611 162.7717 176.9504
```

c) Compare os intervalos dos itens anteriores e explique por que o intervalo de predição é mais amplo.

Analisando os resultados obtidos, pode-se observar que os resultados dos cálculos feitos manualmente não diferem dos obtidos com a função `predict()` do R. O intervalo de predição é mais amplo do que o de confiança, pois além de levar em conta a variabilidade da esperança de Y_0 (valor predito/média da variável resposta), ele também leva em consideração a variabilidade das observações individuais (resíduos).

d) Explique a diferença conceitual entre o intervalo de confiança para o valor médio e o intervalo de predição para um valor individual.

O intervalo de confiança mede o grau da incerteza de uma variável já existente, afim de estimar seu valor a partir dos dados. Já o intervalo de predição mede o grau de incerteza de uma nova observação, de forma a estimar um possível novo valor.

7. ANOVA

a) Monte a tabela ANOVA completa com GL, SQ, QM e teste F manualmente (sem funções prontas do R).

```
# Vetor unitário para facilitar cálculos
u <- matrix(rep(1, n), ncol = 1)

# SQ Total
SQ_total <- t(Y) %*% Y - ((t(u) %*% Y)^2)/n
SQ_total <- as.numeric(SQ_total)

# SQ Regressão
SQ_regressao <- t(betas) %*% t(X) %*% Y - ((t(u) %*% Y)^2)/n
SQ_regressao <- as.numeric(SQ_regressao)

# SQ Resíduos
SQ_residuos <- t(residuos) %*% residuos
SQ_residuos <- as.numeric(SQ_residuos)

# Verificação da decomposição
cat("=== DECOMPOSIÇÃO DA VARIABILIDADE ===\n")
cat("SQ Total:", round(SQ_total, 2), "\n")
cat("SQ Regressão:", round(SQ_regressao, 2), "\n")
cat("SQ Resíduos:", round(SQ_residuos, 2), "\n")
cat("Verificação (SQ_reg + SQ_res):", round(SQ_regressao + SQ_residuos, 2), "\n")
cat("Diferença:", round(SQ_total - (SQ_regressao + SQ_residuos), 8), "\n")
cat("\n")

# Graus de liberdade
GL_regressao <- k # número de covariáveis (4)
GL_residuos <- n - p # n - (k + 1) = 51 - 5 = 46
GL_total <- n - 1

# Quadrados médios
QM_regressao <- SQ_regressao / GL_regressao
QM_residuos <- SQ_residuos / GL_residuos

# Estimador não viesado de sigma^2
sigma2_est <- QM_residuos

cat("=== TABELA ANOVA ===\n")
cat("Fonte de Variação | GL | SQ | QM | F\n")
cat("-----|----|----|----|----\n")
cat("Regressão      |", GL_regressao, "|", round(SQ_regressao, 2),
    "|", round(QM_regressao, 2), "|", round(QM_regressao/QM_residuos, 2), "\n")
cat("Resíduos       |", GL_residuos, "|", round(SQ_residuos, 2),
    "|", round(QM_residuos, 2), "| -\n")
cat("Total          |", GL_total, "|", round(SQ_total, 2), "| - | -\n")

## === DECOMPOSIÇÃO DA VARIABILIDADE ===
## SQ Total: 2546.39
## SQ Regressão: 1868.08
## SQ Resíduos: 678.31
## Verificação (SQ_reg + SQ_res): 2546.39
```



```
## Diferença: -2.9e-07
##
## === TABELA ANOVA ===
## Fonte de Variação | GL | SQ | QM | F
## -----|----|----|----|----|----
## Regressão          | 5 | 1868.08 | 373.62 | 35.25
## Resíduos           | 64 | 678.31 | 10.6 | -
## Total              | 69 | 2546.39 | - | -
```

b) Teste a hipótese H_0 : todos os $\beta_j = 0$ (exceto β_0) vs H_1 : pelo menos um $\beta_j \neq 0$.

```
# Teste F para significância da regressão
# H0: beta1 = beta2 = beta3 = beta4 = 0 vs H1: pelo menos um beta_j != 0
F_calc <- QM_regressao / QM_residuos
alpha <- 0.05
F_critico <- qf(1 - alpha, GL_regressao, GL_residuos)
p_valor_F <- 1 - pf(F_calc, GL_regressao, GL_residuos)

cat("\n=== TESTE F PARA SIGNIFICÂNCIA DA REGRESSÃO ===\n")
cat("H0: beta1 = beta2 = beta3 = beta4 = 0 \n")
cat("H1: pelo menos um beta_j != 0 \n")
cat("F calculado:", round(F_calc, 2), "\n")
cat("F crítico (alpha=0.05):", round(F_critico, 2), "\n")
cat("P-valor:", format(p_valor_F, scientific = TRUE, digits = 3), "\n")

if(F_calc > F_critico) {
  cat("\nDecisão: Rejeita H0 - A regressão é significativa\n")
} else {
  cat("\nDecisão: Não rejeita H0 - A regressão não é significativa\n")
}
```

```
##
## === TESTE F PARA SIGNIFICÂNCIA DA REGRESSÃO ===
## H0: beta1 = beta2 = beta3 = beta4 = 0
## H1: pelo menos um beta_j != 0
## F calculado: 35.25
## F crítico (alpha=0.05): 2.36
## P-valor: 0e+00
##
## Decisão: Rejeita H0 - A regressão é significativa
```

8. Questões Conceituais

a) Quais as suposições do modelo de regressão linear múltipla?

O modelo assume:

- Que a relação entre a variável dependente e as variáveis independentes é linear;
- Que os erros são independentes;
- Que a variância dos erros é constante;
- Que as variáveis independentes não são linearmente dependentes entre si;
- E espera-se média zero dos erros;
- E para os testes de hipótese e intervalos de confiança assumimos a normalidade dos erros.

b) Quais as limitações do modelo de regressão linear múltipla? O modelo pareceu limitado para esse conjunto de dados de altura?

As limitações do modelo de regressão linear múltipla estão relacionadas às suposições do modelo. Como a suposição de linearidade entre os preditores e a variável resposta, a independência e homocedasticidade dos erros, a normalidade dos erros para a realização de testes e intervalos de confiança, e a ausência de multicolinearidade entre os preditores. Quando essas suposições não se verificam, os coeficientes e as inferências podem se tornar imprecisos.

No conjunto de dados BGSgirls, o modelo parece funcionar razoavelmente bem (R^2 ajustado ~ 0.71), mas algumas variáveis, como HT2 e WT2, não mostraram significância, indicando que nem todas contribuem de forma linear para a previsão da altura.

c) Compare os resultados da regressão múltipla com uma regressão simples usando apenas WT9. Qual modelo você prefere e por quê?

Comparando pelo R^2 ajustado dos modelos de regressão simples (HT18 ~ WT9) e de regressão múltipla, observamos que o modelo simples explica apenas 16.95% da variabilidade da altura o que é muito inferior ao poder de explicação do modelo de regressão múltipla de 71.28%. E por conta dessa maior capacidade preditiva o modelo de regressão múltipla é preferível, pois captura a influência combinada de várias variáveis.

```
modelo_simples <- lm(HT18 ~ WT9, data = data)
cat("R^2 ajustado do Modelo de Regressão Simples:",
    round(summary(modelo_simples)$adj.r.squared, 4), "\n")
cat("R^2 ajustado do Modelo de Regressão Múltipla:", round(R2_ajustado, 4), "\n\n")
cat("Detalhes do Modelo Simples (HT18 ~ WT9)")
summary(modelo_simples)
```

```
## R^2 ajustado do Modelo de Regressão Simples: 0.1695
## R^2 ajustado do Modelo de Regressão Múltipla: 0.7128
##
## Detalhes do Modelo Simples (HT18 ~ WT9)
## Call:
## lm(formula = HT18 ~ WT9, data = data)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -10.0230  -2.9735   0.1766   2.5015  16.3872
##
```

```
## Coefficients:
##           Estimate Std. Error t value Pr(>|t|)
## (Intercept) 152.4920      3.6786  41.454 < 2e-16 ***
## WT9         0.4444       0.1144   3.883 0.000236 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 5.536 on 68 degrees of freedom
## Multiple R-squared:  0.1815, Adjusted R-squared:  0.1695
## F-statistic: 15.08 on 1 and 68 DF,  p-value: 0.0002357
```

```
hist(data)
```